


Agent Extracteur

Architecture et Documentation Technique



Description générale du projet

L'**Agent Extracteur** est une composante centrale du système multi-agents de cybersécurité, conçue pour l'**ingestion unifiée** et la **pré-analyse** des données de sécurité provenant de multiples sources hétérogènes.

Objectif principal : Assurer une collecte fiable, asynchrone et sans perte de données de sécurité depuis les sources de logs, le trafic réseau et les alertes SIEM, avec un mécanisme d'arrêt gracieux et une journalisation complète des erreurs.

Structure du code source

Répertoires principaux

`src/agents/` : Contient les agents métier (`extractor.py` avec `SecurityAgent`)

`src/utils/` : Modules utilitaires (`parsers.py`, `shared_memory.py`)

`data/raw/` : Fichiers sources temporaires (logs, trafic, alertes)

`data/processed/` : Canaux de mémoire partagée (JSON)

Module `parsers.py`

Fonctionnalités clé :

- `parse_syslog_line()` : Analyse syntaxique RFC 3164 avec extraction `host/process/message`.
- `parse_tshark_json()` : Parsing du format EK/Elasticsearch pour le trafic réseau imbriqué.
- `generate_deterministic_id()` : Génération SHA-256 d'ID sans surcoût LLM.
- `normalize_severity()` : Conversion des niveaux de criticité vers un score standardisé entre 0 et 1.

Module `extractor.py`

L'agent principal `SecurityAgent` implémente :

- # **Ingestion asynchrone** : Threads dédiés pour syslog (UDP/TCP) et capture réseau (tshark).
- # **Gestion d'erreurs explicite** : Aucun échec silencieux – tout problème est loggué avec `[ ERROR]` ou `[ WARNING]`.
- # **Arrêt gracieux** : Gestion propre de `SIGINT/SIGTERM` avec nettoyage des sockets et des files d'attente.
- # **Détection de pertinence** : Filtrage automatique basé sur des mots-clés de sécurité et scoring algorithmique.

Sources supportées

- ≡ **Syslog (UDP/TCP)** : Port par défaut 1514, format standard RFC 3164.
- ≡ **Capture réseau** : Flux tshark en mode line-buffered via le format EK (`-T ek`).
- ≡ **Alertes SIEM** : Ingestion de fichiers de télémétrie structurés depuis `data/raw/siem_alerts.json`.

Utilisation

Mode daemon (temps réel)

```
python3 src/agents/extractor.py --daemon
```

Mode batch (nettoyage et initialisation)

```
python3 src/agents/extractor.py --cleanup
```